

Inversa: 문제 구성(**construction**)으로 측정하는 — 오염에 강 하고 스스로 난이도를 키우는 — 수학 능력 벤치마크

Woosunghyeun (우성현) — Chungwoon University · nunconnect1@gmail.com

June 8, 2026

작업 논문 – 모든 수치는 이 저장소(*scoring-validity* 브랜치)의 실제 측정값입니다. 그림은 *scripts/make_figures.py*가 결과 파일로부터 생성합니다. (영문 정본 *inversa-paper.md*의 한국어 번역.)

초록

표준 AI 수학 벤치마크는 모델에게 문제를 풀게 합니다(문제 → 답). 여기엔 두 약점이 따릅니다. (1) 고정된 공개 시험셋이 학습 데이터에 유출되어 점수가 실제 추론 이상으로 부풀려지고(오염), (2) 모델이 강해지면 각 벤치마크는 결국 포화되어 더 어려운 문제를 사람이 계속 출제해야 합니다. 우리는 그 역(*inverse*) 과제 – 답을 주고, 그 답이 나오는 문제를 구성하게 하는 것 – 이 더 신뢰할 만한 측정 기반인지 연구합니다. 우리는 기계로 검증되는 점수 **Inversa Generative Score(IGS)**를 정의하며, 이는 *sympy* 오라클로 채점하고 **LLM** 심판을 쓰지 않습니다. 실험별 코호트 7~22개 모델 (및 59개 모델 엔진 리더보드)에서: (i) forward 점수는 우리 모델에서도 오염으로 측정 가능하게 부풀려집니다(GSM8K vs 신선한 GSM-Symbolic, +3.2%, 95% CI [+1.0, +5.7]). 반면 역과제는 체계적 격차가 없고(+0.0%, [-10.5, +11.0]) 설계상 오염 불가능합니다. (ii) IGS는 어려운 비포화 forward 벤치(AIME)와 강하게 일치합니다 – **Spearman +0.93** [+0.65, +1.0] – 즉 검증된 수학 능력 측정기이며, 별개의 능력이 아닙니다(원래의 “생성 ≠ 풀이” 가설은 반증됨) – 그리고 판별 검정(**E13**)은 이 일치가 수학-특이적이며 단순 일반역량이 아님을 보입니다: IGS는 어려운 비수학 논리 통제보다 AIME를 훨씬 더 추종합니다(ρ +0.93 vs +0.66, Williams $p < 0.05$; 편상관 +0.88). (iii) IGS 난이도는 스스로 확장됩니다: 구성 난이도를 올리면(외비우스 → 다항 → 4차/합성 근 변환) 상단 천장이 깨져 어떤 모델도 **100%**에 도달하지 못합니다(최강 opus-4.8도 88%에서 멈춤). 진행 중 우리가 검증하고 기각한 가설들도 보고합니다. 결론: 문제 구성은 별개의 능력이 아니지만, **gold-standard forward** 벤치마크가 재는 바로 그 수학 능력을, 오염에 강하고·자동으로 확장되며·기계로 검증되는 방식으로 측정합니다 – 그 지속적 우위는 새로운 축이 아니라 구조적인 것입니다.

1부 – 起 / 도입: 왜 “푸는 것”의 역을 보는가

1.1 “문제를 풀어라” 벤치마크의 두 문제

forward 벤치마크는 문제를 주고 모델의 답을 채점합니다(GSM8K, MATH, AIME 등 – 지배적 방식). 두 가지 알려진 실패 모드가 있습니다.

- **오염(contamination)**. 공개 시험셋이 온라인에 올라가 사전학습에 흡수됩니다. 그러면 모델은 추론이 아니라 암기(*recall*)로도 높은 점수를 낼 수 있습니다. 이는 경험적으로 입증돼 있습니다 – GSM1k(Zhang 외, Scale AI, 2024, arXiv:2405.00332)는 GSM8K와 평행한 신선 셋을 만들어 일부 계열에서 최대 **13%** 과적합 격차를 측정했고, 사전학습에 테스트 복제본이 하나만 있어도 MATH 손실이 급락하며, 재구성(rephrase) 오염은 n-gram 탐지를 회피합니다(arXiv:2311.04850).
- **포화 / 트레드밀**. 모델이 강해지면 각 벤치마크의 상단이 100%에 근접한 점수로 차서 최강 모델을 더는 못 가립니다 – 100cm까지만 있는 자로는 100cm 넘는 사람을 구별 못 하는 것과 같습니다. 학계는 더 어려운 벤치마크를 출제하며 대응하지만(AIME → FrontierMath) 이는 비싼 인적 트레드밀이고, 새 벤치마크도 결국 유출됩니다.

1.2 아이디어

방향을 뒤집습니다. “문제를 줄 테니 답하라” 대신 “답을 줄 테니 그 답이 나오는 문제를 구성하라”. 두 가지 직관:

- 테스트 시점에 즉석 구성된 문제는 오염될 수 없습니다 – 유출될 고정 문항이 없습니다.
- 구성 난이도는 사람 출제가 아니라 프로그램으로 올릴 수 있습니다(변환 합성, 제약 추가).

검증해야 할 질문은 구성이 (a) 진짜인가(암기가 아닌가), (b) 측정 가능하고 일관적인가, (c) 모델 순위의 신뢰할 만하고 지속적인 기반인가입니다. 이 논문은 이를 직접 검증합니다 – 틀린 것으로 드러난 가설들까지 포함해서.

1.3 가설과 판정 (로드맵)

#	가설	판정	근거
H1	forward 점수는 오염으로 부풀려진다	지지	E12: +3.2% [+1.0,+5.7], 9개 중 8개
H2	역과제는 암기에 강하다	지지	구조적 + E12b: +0.0% [-10.5,+11.0]
H3	역 “생성”은 풀이와 별개 능력이다 ($\theta_{gen} \perp \theta_{solve}$)	기각	E10: IGS $\leftrightarrow$ AIME +0.93 (능력을 추종)
H4	forward 벤치는 일반적으로 포화다	기각/한정	어려운 forward(AIME)는 포화 아님
H5	여기서 forward 풀이는 암기가 아닙니다(초기 과장)	기각	악한 검정; H1/E12로 정정
H6	IGS는 gold-standard 어려운 forward와 같은 능력을 쟁다	지지	E10: +0.93 [+0.65,+1.0]
H7	IGS 난이도를 키워 프런티어를 변별할 수 있다	지지	E8: 천장 돌파, opus 88%
H8	IGS는 일반역량(g)이 아니라 수학-특이적이다	지지	E13: $\rho(\text{IGS}, \text{AIME}) = .93 \gg \rho(\text{IGS}, \text{비수학논리}) = .66$, Williams $p < .05$; 편상관 .88
H9	IGS의 구성 잔차가 순방향 풀이 너머로 구성/검증을 예측한다(중분타당도)	기각	E14: 편상관 $\rho(\text{IGS}, Y \text{AIME}) \leq 0$ ($Y1 = -.20, Y2 = -.42$) – AIME가 동등 이상 예측

정직한 서사: 원래 비전의 강한 형태(완전히 새로운 능력 축)는 거짓이지만, 더 방어 가능한 형태(오염 불가·자동 확장·검증된 측정기)는 성립합니다.

2부 – ⌘/ 방법: **Inversa**가 정확히 어떻게 작동하는가

이 절은 처음 읽는 독자도 모든 단계를 볼 수 있도록 의도적으로 구체적입니다 – 모델에게 무엇을 보내고, 모델이 무엇을 돌려주며, 기계(사람도, 다른 LLM도 아닌)가 어떻게 정답 여부를 판정하는지.

Inversa scoring pipeline: answer -> constructed problem -> machine verification




Figure 1: Inversa 채점 파이프라인

2.1 두 가지 구성 과제

과제 **A** – “**Pose**”(타깃으로부터 구성). 모델에게 목표 답 을 주고, 그 답이 유일 실근이 되는 방정식을 짓게 합니다. 실제 프롬프트:

Construct a single-variable equation in x whose UNIQUE real solution is exactly $\{target\}$. There must be no other real solution. Radicals, fractions, exponentials and logs are allowed and encouraged.

You may reason first, but you MUST end with the equation on its own final line, prefixed by '#### ', in sympy syntax. Example: '#### $x^2 - 2 = 0$ '.

(번역: x 에 대한 단일변수 방정식을, 유일 실근이 정확히 $\{target\}$ 이 되도록 구성하라. 다른 실근이 있어선 안 된다. 유리식·분수·지수·로그 허용. 추론은 해도 되나, 반드시 마지막 줄에 '#### '를 붙여 sympy 문법으로 방정식을 출력하라. 예: '#### $x^2 - 2 = 0$ '.)

타깃은 쉬운 것(3)부터 일부러 외우기 힘든 것($\sqrt{2} + 1, t^3 - t - 1 = 0$ 의 실근, $\sqrt{2} + \sqrt{3}$)까지. 무리수 타깃이 중요한 이유: $\sqrt{2}+1$ 의 뻘한 템플릿은 그 최소다항식 $x^2 - 2x - 1 = 0$ 인데, 이걸 켄레근 $1 - \sqrt{2}$ 도 함께 가져 “유일” 조건을 깹니다 → 모델은 패턴 매칭이 아니라 진짜로 구성해야 합니다(예: $x = \sqrt{2} + 1$, 또는 정의역 제한형).

pose 타깃은 고정 बैं크에서 뽑거나 시험 시점에 새로 생성할 수 있다(--pose-random N): 엔진이 무작위 무리수/구조적 타깃을 샘플링하고(각 타깃의 값은 그 타깃을 기술하는 동일한 기호식에서 sympy로 계산되므로 기술과 정답이 어긋날 수 없다), 시드와 생성 타깃을 출력에 기록한다. 이로써 pose 속도 transform 속처럼 오염 면적이 된다 – 새 타깃엔 유출될 (타깃 → 좋은 방정식) 쌍이 없어, 고정 pose बैं크가 공개되면 원리상 암기될 수 있었던 유일한 비대칭이 닫힌다.

두 번째 강화 --pose-no-trivial은 gaming을 막는다: $x = target$ 같은 1차식은 맞지만 구성이 아니다(정답 복붙)이므로, 검증기가 x 에 대해 1차인 답을 trivial로 표시하고 strict 모드에서 무효 처리한다 – 차수 ≥ 2 또는 비다항식으로 타깃이 유일 실근이 되도록 구성하게 강제한다. 효과는 크다 (소규모 프롬프트에서 복붙을 배제하자 프런티어-mini 모델의 permissive pose 점수가 절반으로 떨어졌다) – 즉 permissive pose는 일부 복붙으로 부풀려져 있다. 따라서 이를 오픈인 엄격 모드로 보고 고하며, 헤드라인 런은 permissive 채점이었으므로 그 pose 절반은 이 단서와 함께 읽어야 한다.

과제 B – “Transform”(암기 불가 핵심). 못생긴(무리수) 실근 r 하나를 갖는 무작위 3차식을 생성해 모델에게 보여주고, r 을 수치로 풀지 말고 근이 $g(r)$ 인 새 방정식을 짓게 합니다. 프롬프트:

Let r be the UNIQUE real solution of this equation:

{source} 예: $x^3 + x - 1 = 0$

Do NOT solve for r numerically. By transforming the structure, construct a NEW single-variable equation in x whose unique real solution is exactly $\{g\}$ (where r is that solution above).

... 반드시 마지막 줄에 '#### '를 붙여 sympy 문법으로 출력. 예: '#### $(x-1)^3 + (x-1) - 1 = 0$ '.

$g = r + 1$ 의 구조적 정답은 치환 $x \rightarrow x - 1$: $(x-1)^3 + (x-1) - 1 = 0$. source가 무작위이고 r 이 무리수이므로 외운 문제로는 답을 낼 수 없습니다 – 출력이 테스트 시점에 제시된 입력의 함수여야 합니다. 이것이 과제 B가 설계상 오염 불가능한 이유입니다.

2.2 응답에서 방정식 추출

모델은 다양한 형식으로 답합니다. extract_equation(tasks/posing.py)은 견고합니다:

1. 마지막 #### 마커 뒤 텍스트를 우선.
2. 없으면 실제로 파싱되는 마지막 줄을 택함.
3. 장식 잡음 정리: LaTeX($\$, \backslash()$ ·코드펜스·선행 Final:/f(x) = 라벨 제거, $\wedge \rightarrow **$ (sympy는 $\wedge$ 를 XOR로 읽음), 유니코드 정규화($x^3 \rightarrow x^{**3}, -/x/\sqrt{}$).
4. 파싱 가능한 방정식이 없으면 식만 다시 출력하라고 1회 재요청.

이게 중요합니다: 없으면 정답이지만 장황한 모델이 거짓 0점이 됩니다(이 수정 전, 형식 미준수만으로 한 모델이 0%로 떨어진 걸 관측).

2.3 검증 – sympy 오라클, LLM 심판 없음

verify_equation(방정식, 타깃)(verifiers/math_equation.py)이 정답 여부를 기계적으로 판정합니다:

1. 파싱 $lhs = rhs.$ = 하나로 분리; 부등식·관계식($Eq(...)$) 거부. 각 변수 `sympy parse_expr` 로 샌드박스(`__builtins__` 제거)에서 파싱 → 신뢰 못 할 모델 출력이 코드 실행 불가.
2. x 존재 요구(x 를 제약하지 않는 식 거부).
3. 풀이 `sp.solve(lhs - rhs, x)`를 10초 타임아웃(데몬 스레드)으로 – 그렇지 않으면 `sympy`가 적대적 입력에서 영원히 멈출 수 있음(실제로 한 실행을 46분 멈추게 함).
4. 실근만 추림. `valid` = 타깃이 그 안에 있음; `unique` = 실근 집합이 정확히 {타깃}(1e-6 이내).
5. 수치 풀백. 기호적으로 타깃을 확인 못 하면(예: 초월식 임베딩 $\exp(x**3 - x - 1) = 1$), 격자 평가 + 이분법으로 멤버십·실근 수를 확인 → `sympy`가 못 푸는 유효 구성도 구제.

예시. 출력 추론...
 $x**3 - 27 = 0$, 타깃 3: 추출 → $x**3 - 27 = 0$; 풀이 → 근 {3, 복소, 복소}; 실근 {3}; `valid=True`, `unique=True` → 인정. 출력 $x**2 - 9 = 0$, 타깃 3: 실근 {3, -3} → `unique=False` → 불인정(-3도 답이므로). 전부 재현. 검사 가능하며, 스위트는 213개 단위테스트(검증기·채점·추출·엔진)를 통과합니다 – `python -m pytest -q`.

2.4 점수: IGS

한 모델에 대해 고정된 pose 타깃 묶음과 transform 항목 묶음을 돌려 두 유효율(각 [0,1])을 계산:

- **pose validity** = 유일해 제약을 만족한 pose 항목 비율;
- **transform validity** = 유일 실근이 $g(r)$ 와 같은 transform 항목 비율.

IGS = mean(pose validity, transform validity).

IGS는 생성 전용이며 forward 풀이는 포함하지 않습니다(포화 참조로만 별도 표기). 엔진은 `python -m inversa.cli_bench --models ...`로, 항목별 증거까지 담은 순위 IGS 리더보드(JSON+HTML)를 출력합니다.

구간 척도화(선택). 원 IGS는 서열 지표다 – 0.9 대 0.8 격차가 구간 전체에서 동일한 크기가 아니고, pose/transform은 임의의 동일 가중으로 합쳐진다. `scripts/build_irt.py`는 실행 캐시에서 모델×문항 정보 행렬을 복원해 **Rasch(1PL)** 모델을 적합하고, 각 모델을 구간 로짓 θ 척도($P(\text{정답}) = \sigma(\theta - b)$)에 놓으며 문항마다 난이도 b ·변별도(point-biserial)를 준다. θ 는 IGS의 단조 재척도라($N=46$ 완전사례 런에서 θ -vs-IGS Spearman +1.00) 순위는 그대로지만 간격이 의미를 갖는다 – 포화된 0.98→1.00 상단이 천장 부근에서 큰 θ 간격으로 벌어진다 – 그리고 두 문항형을 한 행렬로 합쳐 50/50 가중을 없앤다. 출력: `data/results/igs_irt.json`. (가독성을 위해 IGS를 헤드라인으로, θ 를 척도상 정직한 동반 지표로 보고한다.)

2.5 모델·데이터·인프라

- 모델. 실험별 코호트 7~22개 모델(약체 llama-3.1-8b-command-r부터 프런티어 opus-4.8·qwen3.7-plus-deepseek), OpenRouter 경유; 엔진 리더보드(\$3.5)는 59개 모델 / 7개 패밀리. 레이트리밋·크레딧이 일부 모델을 떨어뜨려 실험별 N 은 변동.
- 문제은행(전부 `sympy` 유일근 검증): pose 타깃(고정 बैं크 또는 `--pose-random`으로 즉석 생성, §2.1); transform 항목(무작위 못생긴 근 3차식 × {평행이동·역수·외비우스} 변환), §3.4의 더 어려운 다항/brutal 변환. forward 비교엔 **GSM8K·GSM-Symbolic**(HuggingFace)·**AIME 2024+2025**; 판별/예측 통제(§3.6, §3.8)는 논리 बैं크와 구성/검증 बैं크를 추가.
- 엔진. `cli_bench`는 모든 (모델, 문항) 호출을 단일 상한 풀에 스케줄하며 문항 단위 **resume** 캐시(재실행 시 이미 한 호출은 건너뛴)와 계정 차원 오류 시 즉시 중단(**fast-abort**)을 뒀 – 크래시·네트워크 끊김·크레딧 소진에도 완료분을 잃지 않고 이어서 진행 가능.

3부 – 轉 / 발견 (그리고 이야기가 뒤집힌 지점)

3.1 forward 점수는 오염으로 부풀려진다 (H1) – 그리고 우리의 첫 과장 (H5)

처음엔 악한 자작 섭동 검정(자작 대수의 숫자 교체)을 돌려 forward 풀이가 “진짜이고 암기가 아니다”라고 잘못 결론냈습니다. 실수였습니다: 자작 문항은 오염될 수 없으니 격차가 없는 게 당연했죠. 제대로 된 검정으로 바로잡았습니다:

80개 템플릿에 대해, **GSM8K** 원본(학습 코퍼스에 유출 = 오염) 정확도 vs 매칭된 **GSM-Symbolic** 인스턴스(동일 난이도, 새 숫자, canary 표시) 정확도를 비교. 그 격차가 forward 점수 부풀림입니다.




Figure 2: Forward 오염 격차

결과(N=9): 평균 격차 +3.2%, 95% CI [+1.0%, +5.7%] (0 배제); 9개 중 8개 양수. 약한 모델일수록 큼(llama-3.1-8b +11%), 프런티어는 작음(opus, mistral-small +1%) – GSM1k가 보고한 모델 의존 패턴과 정확히 일치. 즉 **H1**은 우리 모델에서도 성립: 본적 있는 문항이 forward 점수를 부풀립니다. (정직하게 한정합니다: 효과는 실재하나 완만·불균등하며, forward 점수가 광범위하게 “가짜”라고 주장하지 않습니다.)

직접 증거(data/results/forward_gap_results.json; 격차 = GSM8K – GSM-Symbolic 정확도):

모델	GSM8K	GSM-Symbolic	격차
llama-3.1-8b-instruct	78.8%	67.5%	+11.2%
gpt-4o-mini	96.2%	91.2%	+5.0%
gemini-3.5-flash	93.8%	88.8%	+5.0%
llama-3.3-70b-instruct	96.2%	92.5%	+3.7%
qwen-2.5-7b-instruct	90.0%	87.5%	+2.5%
claude-3.5-haiku	90.0%	88.8%	+1.3%
claude-opus-4.8	98.8%	97.5%	+1.3%
mistral-small-2603	91.2%	90.0%	+1.2%
command-r-08-2024	51.2%	53.8%	-2.5%

파일에서 독립 재계산: 평균 +3.19%, 9개 중 8개 양수, 95% 부트스트랩 CI [+1.0, +5.7](20k, seed 0) – 저장된 summary와 일치. 부록 V 참조.

3.2 역과제엔 오염 격차가 없다 (H2)

설계상 과제 B는 무작위 입력을 쓰므로 유출될 고정 문항이 없습니다. 경험적으로(E12b), 친숙/교과서 source($\sqrt[3]{2}$, 플라스틱 수, 뉴턴의 x^3-2x-5) vs 무작위 source의 transform validity를 비교: 평균 격차 +0.0%, 95% CI [-10.5%, +11.0%](N=7) – 체계

적 친숙함 이득 없음. CI가 넓어(작은 표본) 구조적 논거가 주이고 측정은 보강입니다. 핵심은 비대칭: **forward +3.2%(CI가 0 배제) vs inverse +0.0%(CI가 0 포함)**.

직접 증거와 정직한 주의(data/results/inverse_gap_results.json; 격차 = 친숙 - 무작위 source):

모델	친숙	무작위	격차
claude-3.5-haiku	0.37	0.10	+26.7%
llama-3.3-70b-instruct	0.77	0.67	+10.0%
claude-opus-4.8	1.00	1.00	0.0%
gpt-4o-mini	0.60	0.60	0.0%
gemini-3.5-flash	0.90	0.97	-6.7%
qwen-2.5-7b-instruct	0.30	0.37	-6.7%
llama-3.1-8b-instruct	0.07	0.30	-23.3%

평균(+0.0%)은 모델별 큰 반대 스윙(-23%...+27%)의 상쇄이지 총총한 일치가 아닙니다: N=7×30문항이라 모델별 비율이 노이즈가 큼니다. claude-3.5-haiku 이상치(+26.7%)는 정직하게 표기해야 하며, 노이즈가 아니라면 그 모델의 친숙함 이득을 뜻합니다. 그래서 구조적 논거(과제 B는 출력을 무작위 시험시점 입력에 고정 → 유출될 고정 문항이 없음)가 핵심 근거이고, E12b는 그 구조가 집단 수준에서 설계대로 작동함을 보강할 뿐 총총한 귀무 CI로 읽으면 안 됩니다. 독립 재계산: 평균 **+0.00%**, CI [-10.5, +11.0](부록 V).

3.3 큰 전환: IGS는 별개 능력이 아니라 어려운 forward와 일치한다 (H3 기각, H6 지지)

원래 비전은 문제 구성이 풀이와 분리되는 별개 능력이라 주장했습니다. 검증하려면 포화되지 않은 어려운 forward 벤치가 필요했고, 순위를 비교했습니다. **AIME 2024+2025**(정수답 → 정확 채점; 프런티어 모델이 넓게 퍼짐)를 썼습니다.




Figure 3: IGS vs AIME

결과(N=13): $\text{Spearman}(\text{IGS}, \text{AIME}) = +0.93$, 95% CI [+0.65, +1.0]. 이 논문의 핵심 전환:

- 강한 가설(H3, “생성은 별개 축”)은 기각 – +0.93 순위 상관은 IGS가 일반 수학 능력을 추종함을 뜻하며, 직교하는 무언가를 재는 게 아닙니다.
- 유용한 가설(H6)은 지지 – IGS는 gold-standard·고비용·사람 출제 어려운 벤치와 거의 동일하게 모델을 순위 매깁니다. 따라서 IGS는 검증된 수학 능력 측정기입니다.

H4(“forward 일반 포화”)도 기각합니다: AIME는 포화가 아니며 큰 헤드룸으로 모델을 잘 가립니다. 그러니 Inversa의 가치는 “forward는 죽었다”가 아니라, 같은 순위를 오염 불가·자동 생성으로 얻는 경로라는 데 있습니다.

직접 증거(data/results/e10_results.json; AIME = scripts/run_e10.py가 data/banks/aime_set.json 의 60문항 (AIME 2024+2025)을 풀게 해 정수 정확채점):

모델	IGS	AIME
claude-opus-4.8	1.00	100%
gemini-3.1-flash-lite	1.00	50%
claude-haiku-4.5	0.88	50%
llama-4-scout	0.87	30%
gemini-3.5-flash	0.80	27%
gpt-4o-mini	0.73	3%
mistral-large	0.72	23%
llama-3.3-70b-instruct	0.63	17%
mistral-small-2603	0.50	10%
claude-3.5-haiku	0.50	7%
qwen-2.5-7b-instruct	0.18	3%
command-r-08-2024	0.10	0%
llama-3.1-8b-instruct	0.07	0%

$\rho = +0.93$ 의 정직한 해석. 이 상관관계는 범위에 지배됩니다 – 아주 약한 모델(양측 ≈ 0)과 프런티어 (양측 ≈ 1)가 고정점이라 $+0.93$ 은 변별 구간(중간)의 일치율을 과대합니다. 두 사실이 헤드라인을 누릅니다: (i) **CI** 하한이 **+0.65**($N=13$, 상한은 percentile 부트스트랩상 1.0에 고정) – 방어 가능한 주장은 “중강도”이지 “거의 동일”이 아님; (ii) 실제 부분 괴리 존재 – gpt-4o-mini는 구성은 잘하나(IGS 0.73) AIME는 거의 못 푼(3%)으로 IGS 순위가 AIME보다 ~5계단 높음. 따라서 H_3 는 강한 형태(완전 직교)에서만 기각되며, 구성과 풀이는 상관하나 동일하지 않고, 그 잔차 자체가 정보입니다. 독립 재계산 Spearman = **+0.9253**(부록 V). 이 0.93이 단지 일반역량(g)일 뿐이라는 우려는 §3.6에서 정면으로 검정·기각한다.

3.4 난이도는 스스로 확장된다: 상단 천장 돌파 (H7)

쉬운 transform 은행에선 상단이 포화 – 세 모델이 IGS 1.0으로 묶여 최상단을 못 짭니다(자가 너무 짧음). 검증 가능한 수학 안에서 자를 늘릴 수 있을까요? 구성 난이도를 두 단계 올렸고, 각 단계는 최소다항식으로 검증됩니다:

- **hard**: 다항 변환($r = r^2, r^3$) – 단일 치환이 아니라 거듭제곱/소거 필요;
- **brutal**: 4차/합성 변환(r^4, r^2+r, r^3-r) – 더 깊은 소거.




Figure 4: 난이도 escalation

결과: 각 단계가 상단을 더 분해합니다. brutal 은행에선 어떤 모델도 **100%**에 도달 못 함 – 최강(opus-4.8)이 **88%**에서 멈추고, 전 구간 **12%–88%**로 퍼집니다. hard transform으로 IGS를 재계산하면(E10-redux, N=11) E10이 지적한 최상단 해상도 문제가 해소됩니다: 만점 동물 모델 수가 2 → 1로 줄어(AIME와 동일), 구별값은 더 많고(10 vs AIME 9), 순위 일치 유지(+0.89 [+0.47, +0.99]). (이 redux 수치는 파일로 저장돼 있지 않지만 커밋된 transform_hard_results.json + e10_results.json에서 python scripts/e10_redux.py로 결정적으로 재계산되며 – API 불필요 – 정확히 일치함을 확인함; 부록 V.) 재정렬은 균일하지 않고 유의미합니다: 단순 치환은 되나 소거는 못 하는 모델이 붕괴(llama-3.3-70b 77% → 6%) → hard 은행이 더 깊은 구성 능력을 잡니다.

따라서 구성 측은 포화 위로 실제 헤드룸을 가지며, 프로그램으로 검증 가능 한계 안에서 도달 가능합니다 – future-proofing의 핵심(§4.3). 한 가지 단서: 최상위 둘(opus vs qwen3.7-plus) 분리 못 했습니다 – qwen3.7-plus(느린 추론 모델)가 hard 은행에서 타임아웃. 이는 방법이 아니라 인프라 한계입니다.

3.5 엔진 집계 리더보드 (N=59, 정밀 30문항 은행)

벤치마크 엔진(cli_bench)을 OpenRouter 라이브 카탈로그에서 추린 티어 균형 로스터(텍스트 346개 → 진지한 후보 197개 → 시도 102개)에 돌리되, 각 모델을 30문항 pose + 30문항 transform 은행으로 temperature 0(결정적 채점; reasoning 토 큰 예산 4000으로 비용 상한)에서 측정했다. 이 정밀 은행은 기존의 거친 6문항 “표준” pose 은행을 대체한다: pose validity가 1/6이 아니라 **1/30** 단위로 분해되어, 하드 은행 tiebreak 없이도 pose 측 자체에서 모델이 분리된다.

IGS leaderboard (N=59, 30-item banks, temp 0; * = truncated/low-confidence)




Figure 5: IGS 리더보드 (30문항 은행, N=59; amber * = truncation·저신뢰)

7개 패밀리 59개 모델이 완주(IGS 0.18 → 1.00). 3개 모델이 천장(IGS 1.0: gpt-5-mini, gpt-5, qwen3-max)에서 동률 – 거친 은행의 5중 동률보다 훨씬 좁아져 정밀 은행의 높은 해상도를 확인한다. 강한 모델은 transform validity가 1.0 부근에서 포화되는 반면 pose validity는 0.23 → 1.00으로 퍼지므로, 변별은 pose 측이 담당한다. 약한 오픈 모델(qwen3-8b 0.18, claude-3-haiku 0.22)이 하단을 고정한다.

범위와 신뢰도(정직). 이것은 단일 패스(반복 1회, temperature 0)다. 패스 도중 계정 크레딧이 소진되었고, 엔진은 계정 차원 오류를 감지해 즉시 중단하고 캐시를 보존하므로 디스크에서 재개 가능하다 – 다만 102개 중 나머지 43개는 미측정으로 남았다: 후순위 로스터 패밀리(meta-llama, x-ai, minimax, moonshot, cohere, amazon, nvidia, ...)가 잘렸고, 통상의 provider 비호환(non-serverless / 404 / 엔드포인트 미지원)분도 포함된다. 추론·대형 모델 10개는 최종 식을 내기 전에 잘려(그 pose

점수는 신뢰도 낮음 – 예: glm-5는 60문항 중 27문항만 측정) 대시보드에 표시된다. 전체 순위·범위 회계: `data/results/igs_dashboard.html` 및 `igs_leaderboard_30.json`. 로스터 완주는 같은 `--cache`로 크레딧만 충전하면 되는 재실행이다 (이미 측정된 모델은 건너뛰므로 미측정분만 과금된다).

3.6 판별타당도: IGS는 일반역량이 아니라 수학을 쟀다 (H8)

IGS↔AIME 상관(§3.3)이 높다고 곧 “수학 측정기”인 것은 아니다: 강한 모델은 대체로 뭐든 잘하므로(일반 역량 인자 g 가 큼) 넓은 모델 범위에서 거의 모든 두 벤치가 상관한다. 수렴 결과만으로는 “IGS=수학시험”과 “IGS= g 측정기”를 구분할 수 없다. 그래서 판별타당도를 검증한다 – IGS는 AIME(수학)를 비수학 측보다 더 추종하는가? 같은 E10 모델들을 어려운 비수학 통제로 측정했다: 18개의 연역 논리 순서 퍼즐 (산수 없음; 프롬프트와 정답키를 하나의 제약 명세에서 생성하고 유일해를 브루트포스로 검증해 정답키가 구성상 옳음 – `data/banks/nonmath_logic.json`). 핵심은 이 통제가 모델을 변별 (50%–100%)한다는 점이다 – 사실(지식) 통제는 이 모델들이 포화시켜(난해한 사실 뱅크에서도 92%–100%) 변별 없는 무효 통제였다.

결과(N=13): $\rho(\text{IGS}, \text{AIME}) = +0.93$, 그러나 $\rho(\text{IGS}, \text{논리}) = +0.66$ [+0.17, +0.81]; 일반역량 기준선 $\rho(\text{AIME}, \text{논리}) = +0.79$. IGS↔AIME는 둘 다 초과하고, 논리 측을 편상관으로 통제해도 살아남는다: 편상관 $\rho(\text{IGS}, \text{AIME} \mid \text{논리}) = +0.88$. 0.93 대 0.66 격차는 작은 표본에도 통계적으로 유의하다 (종속 상관 차이에 대한 Williams 검정, $t = 3.49$, $df = 10$, $p < 0.05$). 메커니즘은 약한 꼬리에서 보인다: llama-3.1-8b는 논리 퍼즐을 그런대로 풀지만(78%) IGS·AIME 모두 ≈ 0 – 추론은 되나 수학을 구성·풀지 못하며, IGS는 후자를 추종한다. 즉 양극단이 모두 배제된다: IGS는 직교하는 새 측이 아니고(H3 기각: AIME와 $\rho=0.93$) 단순 일반역량도 아니다(H8 지지: 수학-특이적). 단서: N=13(넓은 CI); 비수학 통제 1중; 상위 9개는 논리 통제를 포화시켜 판별 신호는 중하위 범위가 담당; Williams는 Pearson 가정을 Spearman에 근사 적용. 출처/재현: `python scripts/run_discriminant.py --bank data/banks/nonmath_logic.json → data/results/discriminant_results.json`.

3.7 IGS가 측정하는 능력(construct)

메커니즘을 거꾸로 읽으면: IGS는 모델에게 목표(목표 답, 또는 무작위 근의 변환)를 주고 그 목표를 증명 가능하게·유일하게 만족하는 방정식을 짓게 한 뒤 `sympy` 오라클로 확인한다. 점수를 얻으려면 모델은 (i) 목표로부터 거꾸로 구조를 합성하고(순방향 탐색이 아닌 생성/역방향 추론), (ii) 자기 구성을 순방향으로 풀어 목표에 맞는지 확인하고, (iii) 실패집합 전체를 추론해 유일성을 보장하며(근 하나 존재가 아님), (iv) 정확히 맞아야 한다(기계 검증 – 자신감만으로 0점). 따라서 `construct`는 정확한 명세 아래 자기검증을 동반하는 목표지향적 구성적 형식추론 – 계산이 아니고(산술은 오라클이), 암기가 아니며(transform은 암기 불가, `--pose-random`이면 `pose`도), §3.6대로 일반역량이 아니라 수학-특이적이다.

(ii) 단계가 푸는 능력을 요구하므로 IGS는 순방향 풀이를 포함하고 그 분산 대부분을 공유한다(E10의 $\rho=0.93$). 그 위에 더 해지는 고유 부분이 구성·자기검증 잔차다:

$$\text{IGS} \approx (\text{순방향 풀이력}) + (\text{구성·자기검증 잔차}).$$

두 단서가 이를 더 또렷이 한다. 첫째, `construct`는 모드 의존적이다: `permissive pose`는 답을 복붙 ($x = \text{target}$)해도 통과 되는데 이는 풀이가 전혀 필요 없다 – 그래서 `permissive` IGS는 지지분하다(gpt-4o-mini가 IGS 0.73인데 AIME 3%인 이유); `strict` 모드(`--pose-no-trivial`, §2.1)가 이를 제거해 진짜 구성을 분리한다. 둘째, 구성과 풀이는 유일성 검증으로 얹혀 있어 IGS가 둘을 완전히 분리하지 못한다 – 구성 잔차가 얼마나 독립적으로 중요한지를 §3.8의 예측타당도 검정이 데이터에 묻는다(결과는 부정).

3.8 예측타당도: 구성 잔차는 순방향 풀이 너머를 예측하지 못한다 (H9 기각)

E13은 IGS가 AIME와 수학-특이적 분산을 공유함을 보였다. 그런데 그 고유한 구성·자기검증 잔차(§3.7)가 쓸모 있는가 – 순방향 점수가 못 하는 결과를 예측하는가? E10 코호트에서 `pose/transform`과 다른 두 기계채점 결과로 증분 타당도를 검정했다: Y_1 = 제약·구성(차수·필수근·최고차항·서로 다른 실근 수 등 여러 정확 제약을 동시에 만족하는 다항식 구성, `sympy` 검증), Y_2 = 오류검출(주장된 해/인수분해의 참거짓을 yes/no로 라벨). 각각 AIME를 통제한 뒤 IGS가 그 결과를 예측하는지 본다.

결과(N=13): 기각 — 둘 다 편상관 $\rho(\text{IGS}, Y | \text{AIME}) \leq 0$. Y1: $\rho(\text{IGS}, Y) = +0.55$ vs $\rho(\text{AIME}, Y) = +0.66$, 편상관 **-0.20**. Y2: $\rho(\text{IGS}, Y) = +0.72$ vs $\rho(\text{AIME}, Y) = +0.87$, 편상관 **-0.42**. AIME가 두 결과를 IGS만큼 혹은 더 잘 예측하고, AIME 통제 후 IGS는 추가 기여가 없다 — 구성 결과에서조차. 즉 구성 잔차는 순방향 풀이를 넘어서는 증분 예측력이 없다. 이는 논문의 척추와 일치한다: IGS는 추가 예측력을 가진 별개 능력이 아니며, 그 가치는 구조적(오염 면역·자동 확장·수학·특이적 순위)이지 새로운 예측 차원이 아니다. 단서: 이 코호트의 IGS는 *permissive* 쉬운-뱅크 점수(\$3.7은 *strict*가 더 깨끗한 *construct*라 보지만 증분타당도엔 미검정); N=13 넓은 CI(Y1 [-0.09, +0.79]); 결과 자체도 풀이 부하가 큼. 설계-데이터: docs/specs/2026-06-08-e14-predictive-validity.md, data/results/predictive_results.json.

4부 — 結 / 결론

4.1 Inversa는 무엇이고, 무엇이 아닌가

- 이다: 기계 검증(sympy, LLM 심판 없음)·오염 저항(forward +3.2% vs inverse ≈ 0)·자가 확장(외비우스 $\rightarrow r^2 \rightarrow r^4$ 로 천장 돌파)·검증됨(AIME와 $\rho=0.93$ 일치)인 수학 능력 측정기.
- 아니다: 새로운 별개 능력(H3 기각 — 일반 능력을 추종), 어려운 forward보다 본질적으로 더 날카로운 변별자도 아님(동일 난이도에선 대등).
- 지속적 우위(구조적): 구성된 문제를 검증하는 건 구성이 어려워도 쉽니다(P-vs-NP식 비대칭). 그래서 더 어려운 Inversa 항목은 코드 몇 줄이면 되고 오염도 없는 반면, 더 어려운 forward 항목은 비싼 사람 출제가 필요하고 결국 유출됩니다.

4.2 타당성 위험 (정적)

- 보통 N(12~22)에 동률 있음 $\rightarrow$ 상관에 부트스트랩 CI를 달았으나 폭은 넓음.
- 단일 도메인(단변수 대수); 일반화 미검증($\rightarrow$ §4.3).
- 오염 격차는 유출과 표면취약성을 섞음(분리 안 함).
- inverse 격차 CI가 넓음; 구조적 논거가 주.
- 싼 검증은 대수 영역에서 성립; 초월식 유일성은 비싸거나 미결정적일 수 있음(타임아웃+수치 풀백으로 완화). 이것이 제기하는 더 깊은 범위 질문 — 자가확장에 천장이 있는가 — 은 아래 검증 가능성 지평선 노트 참조; 이는 Inversa 고유의 결함이 아니라 평가 자체의 경계다.
- 극난도 측정은 느린 추론 모델에 latency-bound(qwen3.7-plus).
- 추론 모델은 **truncation(#### 식 전에 예산 소진)**이 날 수 있는데, 헤드라인 런은 이를 오답으로 채점했다(강한 모델을 깬 거짓 0). --truncation-missing은 truncated 항목을 결측(분모에서 제외, 오답 아님)으로 처리한다; 어댑터가 각 truncated 호출을 표시하고 결측 수를 보고하므로 옴트인 엄격 모드다.

검증 가능성 지평선에 대하여 (결함이 아니라 범위). 자연스러운 우려: 구성이 검증을 앞지르는 곳 — 초월/미결정 영역 —에선 답 확인이 답 생산보다 비싸져 자가확장이 깨진다. 이는 사실이나, 객관 평가 자체의 경계이며 그 경계는 인간 이해가 아니라 형식적 검증 가능성이다. 네 영역: (a) 값싸게 검증 (sympy 수초 — Inversa 스위트스팟); (b) 검증 가능하나 비쌌(긴 형식증명); (c) 인간은 못 읽어도 기계가 검증 — 예: 사색정리와 케플러 추측의 Flyspeck 증명은 어떤 인간도 끝까지 안 읽지만 증명검사가 객관적 으로 인증; (d) 진정 미결정 — 건전·종료하는 검증자가 없는 곳. 구성>검증 비대칭은 (a)–(c)에서 성립하므로, 건전한 검사기(sympy, 또는 Lean/Coq 증명검사기)는 채점 가능 지평선을 인간이 따라갈 수 있는 한계 훨씬 너머로 확장한다 — 초월적 답도 형식적으로 검증만 되면 객관 채점 가능하며, 이는 LLM 심판이 아니다. 오직 (d)만 채점을 무너뜨리고, 거기선 모든 객관 벤치마크가 동시에 무너져 AI가 AI를 심판하는 길(=Inversa가 제공하려던 객관성을 포기; 측정이 아니라 동료심사)만 남는다. 결정적으로 비교는 Inversa에 유리하다: **forward** 벤치는 이미 답을 아는 문제만 낼 수 있는 반면, Inversa는 구성물을 명세에 검증만 하면 되므로 그 지평선(형식 검증 가능한 명세)이 답-기반 지평선보다 더 멀리 간다. 따라서 검증 한계는 Inversa가 답-기반 방법보다 더 늦게 멈추는 지점이지, Inversa 고유의 약점이 아니다.

4.3 더 강한 논문을 위해 남은 것

- **E4** — 일반화: 대수 너머(정수론·연립·증명)로 재현해 구성이 대수 한정인 아님을 입증.
- **E14** — 예측(증분) 타당도: 검정 완료, 기각(**§3.8**). IGS는 AIME 너머로 구성/검증 결과를 예측하지 못했다(편상관 $\rho \leq 0$). 남은 것: *strict* IGS(더 깨끗한 *construct*, \$3.7)로 재검정, 그리고 생태적 타당도 — IGS가 자체 수학 벤치로는 못 잡는 진짜

외부 결과(실세계 수학 활용·전문가 평가)를 예측하는가? 이것이 예측타당도의 열린 형태이며, 자체 증분 검정은 이미 답을 얻었다.

- **E2** – 신뢰도: 재검사 안정성·과제 간 일관성.
- 더 큰 **N**으로 모든 CI를 좁히고, 한 난이도 단계 더로 최상위를 분리.

4.4 한 줄 결론

문제 구성은 별개 능력이 아니지만 – 기계 검증 가능하고·오염에 면역이며·싸게 확장되는 반면 어려운 forward 벤치는 그렇지 못하므로 – gold-standard forward 벤치가 재는 바로 그 수학 능력을 재면서 모델이 강해져도 계속 변별하는, 지속적이고 신뢰할 만한 도구다.

재현성

저장소 `wooosshh/inversa-bench`, 브랜치 `scoring-validity`. 엔진: `python -m inversa.cli_bench`. 핵심: `tasks/structural.py`, `verifiers/math_equation.py`, `scoring.py`. 실험: `scripts/run_forward_gap.py(E12)`, `run_inverse_gap.py(E12b)`, `run_e10.py+e10_redux.py(E10)`, `run_transform_hard.py+gen_transform_{hard,brutal}_bank.py(E8)`, `run_discriminant.py(E13)`, `run_predictive.py(E14)`, `build_irt.py(Rasch 0)`, `build_dashboard.py`. 그림: `scripts/make_figures.py`. 타당도 강화 엔진 플래그: `--pose-random`(오염 면역 `pose`, §2.1)·`--pose-no-trivial`(자명형 차단, §2.1)·`--truncation-missing`(§4.2)·`--cache(resume)`. 모든 점수는 sympy 검증; **213**개 단위테스트가 검증기·채점·추출·엔진을 커버(`python -m pytest -q`). 결과 JSON은 `data/results/`, 은행은 `data/banks/`.

부록 V – 검증과 재현 (모든 헤드라인 수치 → 출처 → 재계산 방법)

이 논문의 모든 정량 주장은 커밋된 결과 파일에서 독립적으로 재계산(저장된 summary를 그대로 읽은 게 아님)했으며, 브랜치 `scoring-validity` 기준으로 보고값과 명시 정밀도까지 일치한다. 아래 표로 독자는 이 문서만으로 각 주장을 검증할 수 있다: 출처 파일, 저장값, 독립 재계산값, 재생성 명령.

주장(\$)	출처 파일(data/results/)	저장값	독립 재계산	재현
forward 격차 +3.2% [+1.0,+5.7], N=9, 8/9 양수 (§3.1)	<code>forward_gap_results.json</code>	mean 0.0319; CI [0.0097,0.0569]; 양수 8	평균 +3.19% , 8/9, CI [+1.0,+5.7](20k, seed 0)	<code>run_forward_gap.py</code> ; models[]의 평균(c-f)
inverse 격차 +0.0% [-10.5,+11.0], N=7 (§3.2)	<code>inverse_gap_results.json</code>	mean ≈0; CI [-0.105,+0.110]	평균 +0.00% ; 모델별 -23%...+27%	<code>run_inverse_gap.py</code>
IGS↔AIME ρ = +0.93 [+0.65,+1.0], N=13 (§3.3)	<code>e10_results.json</code>	0.9253; CI [0.652,1.0]; n 13	Spearman +0.9253	<code>run_e10.py</code> ; AIME=aime_set.json(60문항)
E10-redux +0.89 [+0.47,+0.99], N=11; 동틀 2→1; 레벨 10 vs 9 (§3.4)	(미저장) <code>transform_hard_results.json+e10_results.json</code>	—	+0.89 , 동틀 2→1, 구별 10 vs 9	<code>scripts/e10_redux.py</code> (API 불필요)
E8 brutal: opus 88% , 12-88% , 100% 없음 (§3.4)	<code>transform_brutal_results.json</code>	opus 0.875; max 0.875; min 0.125	opus 87.5% , 12.5-87.5%	모델별 <code>hard_transform_validity</code> (7개)
E8 hard: llama-3.3-70b 77%→6% (§3.4)	<code>transform_hard_results.json+paper_level3_all.json</code>	easy 0.77 → hard 0.056	77% → 5.6%	모델별 필드
리더보드 N=59 , 7패밀리, IGS 0.18-1.0 (§3.5)	<code>igs_leaderboard_30.json</code> ; <code>igs_dashboard_summary.json</code>	n_models 59; igs_min 0.183	59/102 , 7패밀리	<code>cli_bench ...</code> ; <code>build_dashboard.py</code>
판별타당도 (E13, §3.6): $\rho(\text{IGS}, \text{AIME})=.93 \gg \rho(\text{IGS}, \text{논리})=.66$, Williams t=3.49 p<.05, 편상관=.88	<code>discriminant_results.json</code> (통제 <code>data/banks/nonmath_logic.json</code>)	strong_supported=true; williams_t 3.487; 비수학 range 0.50	재도출: gap +0.27, 편상관 +0.88, Williams t=3.49	python <code>scripts/run_discriminant.py</code> --bank <code>data/banks/nonmath_logic.json</code>
구간(Rasch) 척도화 (§2.4): θ 는 IGS의 단조 재척도, θ -vs-IGS Spearman +1.00 (N=46)	<code>igs_irt.json</code>	n_models 46, n_items 60	실행 캐시에서 재도출, API 불필요	python <code>scripts/build_irt.py</code>
예측타당도 (E14, §3.8): 편상관 $\rho(\text{IGS}, Y \text{AIME}) \leq 0 \rightarrow$ 기각(증분 예측 없음)	<code>predictive_results.json</code>	Y1 편상관 -0.20, Y2 -0.42	재도출: 편상관·gap·포화가드	python <code>scripts/run_predictive.py</code>
검증기 건전성	<code>tests/</code>	—	213개 통과	python -m pytest -q

수치와 함께 읽어야 할 범위 주의: (i) §3.3의 ρ 는 범위 지배 – 극단(약함·프런티어)에 고정됨. 방어값은 CI 하한(+0.65; redux +0.47), gpt-4o-mini(IGS 0.73 / AIME 3%)는 실제 부분 괴리. (ii) §3.2의 inverse 격차 평균은 $\pm 25\%$ 모델별 스윙의 상쇄($N=7 \times 30$ 문항)이므로 구조적 논거가 주이지 귀무 CI가 아님. (iii) §3.4의 천장 돌파와 §3.5의 리더보드는 부분 커버리지(brutal 7개·qwen3.7-plus 타임아웃; 59개 리더보드는 크레딧 제한 단일 패스, truncation 10개 저신뢰 표기). 모든 단서는 §4.2.

참고문헌. GSM-Symbolic – Mirzadeh 외, Apple, ICLR 2025 (arXiv:2410.05229). GSM1k – Zhang 외, Scale AI, 2024 (arXiv:2405.00332). 재구성 오염 – arXiv:2311.04850.